2026C

2026 MCM Problem C: Data With The Stars

1. 背景介绍

《与星共舞》(Dancing with the Stars, DWTS) 是英国节目《舞动奇迹》(Strictly Come Dancing) 的美国版电视特许经营节目。该节目的版本已出现在阿尔巴尼亚、阿根廷、澳大利亚、中国、法国、印度和许多其他国家。本题关注的美国版已经完成了34季。

名人与职业舞者搭档，每周表演舞蹈。一个专家评审团为每对选手的舞蹈打分，粉丝们则（通过电话或网络）为他们该周最喜欢的组合投票。粉丝可以投一票，也可以投多票，上限会在每周公布。此外，粉丝是投票给希望留下的明星，而不能投票淘汰某位明星。裁判评分和粉丝投票结合起来，决定该周淘汰哪一对组合（综合得分最低者）。三对（某些季度更多）组合进入决赛，在决赛周，粉丝和裁判的综合得分用于将他们从第1名排到第3名（或第4、第5名）。

结合粉丝投票和裁判评分的方法有很多种。

- **排名法 (Rank)**：在美国版的前两季中，这种结合是基于排名的。
- **百分比法 (Percentage)**：第2季出现的担忧（由于名人选手 Jerry Rice 尽管裁判评分很低却成为了决赛选手）导致了修改，改用百分比代替排名。
- **回归排名法**：在第27季，发生了另一起“争议”，名人选手 Bobby Bones 尽管裁判评分持续走低却赢得了冠军。作为回应，从第28季开始，淘汰流程做了一点微小的修改。首先利用裁判评分和粉丝投票的综合结果确定倒数两名选手，然后在直播节目中，裁判投票选择淘汰这两名中的哪一位。大约在同一季，制片人也恢复了使用排名法。这一变化发生的确切季度尚不清楚，但有理由假设是第28季。

裁判评分旨在反映哪些舞者在技术上更好，尽管对于什么让舞蹈更好存在一定的主观性。粉丝投票可能更加主观，受舞蹈质量的影响，也受名人的知名度和个人魅力的影响。节目制作人实际上可能在某种程度上更喜欢意见和投票的冲突，因为这种情况会提升粉丝的兴趣和兴奋度。

---

2. 问题要求

提供的数据包含裁判评分和选手信息。您可以自行决定包含额外信息或其他数据，但必须完整记录来源。利用这些数据完成以下任务：

任务 1：粉丝投票估算

- 建立数学模型（或多个模型），**为每位选手在参赛周估算粉丝投票数**（这是未知的且被严密保守的秘密）。
- 您的模型估算的粉丝投票结果是否与每周被淘汰的结果一致？提供一致性的度量标准。

- 您得出的粉丝投票总数有多大的确定性？这种确定性对于每个选手/每周是否总是相同的？提供估算确定性的度量标准。

任务 2：赛制比较与分析

利用您的粉丝投票估算值和其余数据：

- 比较和对比节目使用的两种结合裁判和粉丝投票的方法（即**排名法**和**百分比法**）在不同季度的结果（即对每一季应用这两种方法）。
- 如果结果存在差异，是否有一种方法看起来比另一种更偏向粉丝投票？
- 检查这两种投票方法在发生“争议”（即裁判和粉丝之间存在分歧）的特定名人身上的应用。
  - 结合裁判评分和粉丝投票的方法的选择，是否会导致这些选手的比赛结果相同？
  - 加入额外的机制（即裁判从倒数两名组合中选择淘汰谁）会对结果产生怎样的影响？
  - **参考示例**：
    - 第2季：Jerry Rice，尽管在5周中裁判评分最低，却获得亚军。
    - 第4季：Billy Ray Cyrus，尽管在6周中裁判评分垫底，却获得第5名。
    - 第11季：Bristol Palin，有12次裁判评分最低，却获得第3名。
    - 第27季：Bobby Bones，尽管裁判评分持续很低，却赢得了冠军。
- 基于您的分析，您会建议未来的赛季使用这两种方法中的哪一种？为什么？
- 您是否建议包含“裁判从倒数两名组合中选择”这一额外机制？

任务 3：影响因素建模

利用数据（包括您的粉丝投票估算值）建立一个模型，分析各种职业舞者以及数据中可用的名人特征（年龄、行业等）的影响。

- 这些因素对名人在比赛中的表现有多大影响？
- 它们对裁判评分和粉丝投票的影响方式是否相同？

任务 4：新系统提案

提出另一种结合每周粉丝投票和裁判评分的系统，您认为该系统更“公平”（或者在其他方面“更好”，例如让粉丝觉得节目更刺激）。

- 提供支持理由，说明为何节目制作人应采纳您的方法。

---

3. 提交说明

- 撰写一份不超过 **25页** 的报告陈述您的发现。

- 包含一份 **1-2页的备忘录 (Memo)**，总结您的结果，就裁判评分与粉丝投票的结合方式的影响向《与星共舞》制作人提供建议，并对未来季度如何操作提出推荐意见。
- PDF 解决方案应包含：摘要页、目录、完整解决方案、备忘录、参考文献列表、AI使用报告（如有）。

---

4. 数据说明

数据文件： `2026_MCM_Problem_C_Data.csv`
包含第1–34季的选手信息、结果和每周裁判评分。

表1：变量描述

变量名	解释	示例
celebrity name / ballroom partner	名人选手姓名 / 职业舞者搭档姓名	Jerry Rice / Cheryl Burke
celebrity industry	明星职业类别	Athlete, Model
celebrity homestate	明星家乡州（如来自美国）	Ohio, Maine
celebrity homecountry/region	明星家乡国家/地区	United States, England
celebrity age during season	明星在该季时的年龄	32, 29
season	节目季度	1, 2, ..., 32
results	赛季结果	1st Place, Eliminated Week 2
placement	最终排名（1为最好）	1, 2, 3
weekX_judgeY_score	第 X 周裁判 Y 的评分	1, 2, 3...

数据注释 (Notes on Data)：

1. 每次舞蹈的裁判评分从 1（低）到 10（高）。
    - a. 若某周每位名人表演多支舞蹈，分数为平均值（可能含小数，如 8.5）。
    - b. 奖励分（斗舞等）平均分摊在裁判/舞蹈分数中。
    - c. 团队舞蹈分数与个人分数平均计算。
2. 裁判按评分顺序列出；因此，“裁判 Y”在不同周或不同季可能不是同一位裁判。
3. 不同季度的名人数量不同，节目播出的周数也不同。
4. **第15季**是唯一一季由回归名人组成的全明星阵容。
5. 偶尔会有某周没有名人被淘汰，或者有超过一名被淘汰的情况。
6. `N/A` 值的情况：
    - a. 第4位裁判的分数（如果该周只有3位裁判）。
    - b. 某季中节目未播出的周次（例如第1季只有6周，第7–11周为N/A）。
7. 被淘汰的名人记录为 **0分**。

---

5. 附录：投票方案示例

1. 按排名结合 (COMBINED BY RANK)

(用于第1、2季及第28–34季)

裁判评分和粉丝投票按排名结合。**排名数字相加，总和最大者（表现最差）被淘汰。**
示例（第1季第4周）：Rachel Hunter 被淘汰（综合排名最差）。
由于 Rachel 裁判排名第2（较好），为了被淘汰，她的粉丝排名必须很低（第4名），导致总排名分数为 $2+4=6$（全场最高/最差）。

选手	裁判总分	裁判排名	粉丝票数(假设)	粉丝排名(假设)	排名之和
Rachel Hunter	25	2	110万	4	**6** (淘汰)
Joey McIntyre	20	4	370万	1	5
John O'Hurley	21	3	320万	2	5
Kelly Monaco	26	1	200万	3	4

2. 按百分比结合 (COMBINED BY PERCENT)

(用于第3季至27季)

裁判分数占比 + 粉丝票数占比 = 总百分比。**总百分比最低者被淘汰。**
裁判百分比计算：选手得分 / 当周所有选手总得分。
示例（第5季第9周）：Jennie Garth 被淘汰。

选手	裁判总分	裁判百分比	粉丝票数(假设)	粉丝百分比(假设)	百分比之和
Jennie Garth	29	24.8%	110万	11%	**35.8** (淘汰)
Marie Osmond	28	23.9%	370万	37%	60.9
Mel B	30	25.6%	320万	32%	57.8
Helio Castroneves	30	25.6%	200万	20%	45.6

参考思路

1. 问题背景

1. 从“预测”到“反演”的思维转变

本题表面上是一个数据分析问题，但其数学本质是一个**逆问题 (Inverse Problem)** 和 **参数估计 (Parameter Estimation)** 问题。通常的建模竞赛要求我们根据 X（输入）预测 Y（输出）。然而，在本题中：

- **已知量 (Y)**：每周的淘汰结果（Elimination Results）和最终排名。

- **已知输入 (X_1)**：裁判评分（Judge Scores）。
- **未知隐变量 (X_2)**：粉丝投票（Fan Votes），这是题目明确指出“未知且保密”的核心变量。
- **已知机制 (f)**：两种不同的计分规则（排名制 Rank 和百分比制 Percent）。

我们的核心任务不是预测谁会赢，而是**重构**那段缺失的历史数据——粉丝投票。

1. 核心矛盾：技术评价 vs. 大众心理

题目中反复提到的“争议”案例（如 Jerry Rice, Bobby Bones），揭示了问题的核心矛盾：**基数效用 (Cardinal Utility) 与序数效用 (Ordinal Utility) 的冲突**。

- **裁判分**通常代表技术指标，具有较低的方差（大多数人得分为6–9分）。
- **粉丝票**代表情感指标，极可能呈现幂律分布（Power Law），即头部明星吸走了绝大多数票数。
- **不同的聚合方式**（Rank vs. Percent）决定了这两种效用如何博弈。排名制抹平了极值的影响，而百分比制允许极值（海量粉丝票）主导结果。

2. 数据预处理

数据文件 `2026_MCM_Problem_C_Data.csv` 必须经过清洗，否则模型将产生严重偏差。

1. **数据清洗与分数计算**： 原始数据包含多列评委打分（`Judge Score 1` 至 `Judge Score 10`），其中存在大量非数值字符（如 "N/A"）和空值。处理过程中首先将这些分数列强制转换为数值类型，剔除无效数据。随后，针对每一行数据（代表某选手在某周的表现），计算所有有效评委分数的算术平均值作为该周的“最终得分”。特别地，为了保证折线图的视觉逻辑性，对于平均分为 0 的记录（通常意味着未参赛或已淘汰），将其处理为 `NaN`（空值），从而使折线在选手中途退赛或被淘汰时断开，避免线条骤降至零刻度线。
2. **淘汰信息提取**： 淘汰数据隐藏在文本形式的 `result` 列中。通过正则表达式匹配模式 `(Eliminated|Withdrew).*Week (\d+)`，精确提取出每位选手被淘汰或退赛的具体周数。这一步骤将非结构化的文本描述转化为可量化的数值（淘汰周），并通过聚合统计，计算出每个赛季每一周的淘汰总人数。这为后续分析比赛进程的激烈程度提供了量化指标。
3. **多维度数据整合与可视化**： 最终分析将“选手表现”与“赛制进程”相结合。通过按 `Season`（赛季）分组，构建了双轴对比图表。

3. 问题分析

问题一：

在这个问题中，我们面对的是一种非常典型、但又不容易被直接求解的“逆向建模”任务。比赛的基本机制是这样的：每一轮比赛中，选手同时接受评委打分和粉丝投票，最终的排名由二者综合决定。然而，题目并没有直接给出粉丝投票的数据，而是只给出了评委打分以及最终的

排名结果。我们的目标正是基于这些有限的信息，反向推断粉丝投票的可能情况，或者至少给出一个合理的估计范围。

设每轮比赛共有 n 名选手，编号为 $i = 1, 2, \ldots, n$。

- 评委打分（已知）：J_i
- 粉丝投票数（未知）：$V_i \geq 0$
- 粉丝总票数：

$$S = \sum_{i=1}^{n} V_i$$

- 评委得分比例（已知）：

$$j_i = \frac{J_i}{\sum_{k=1}^{n} J_k}$$

- 粉丝投票比例（未知）：

$$f_i = \frac{V_i}{S}, \qquad \sum_{i=1}^{n} f_i = 1$$

这是全题的基础。由于无法求出唯一解，我们应求解粉丝投票的**概率分布**。可以尝试使用基于约束满足的蒙特卡洛模拟去求解。

> **基于约束满足的蒙特卡洛模拟**
>
> 核心思想是在所有**满足已知规则与观测结果的可行解空间**中进行随机采样。通过将未知量视为随机变量，并在硬约束条件下构造随机过程，可以得到这些未知量在可行空间内的经验分布，从而估计其典型取值、变化范围及不确定性。

在本题中，评委打分与最终排名构成了对粉丝投票的**约束条件**，而粉丝投票本身则是需要被反向估计的未知量。蒙特卡洛模拟的作用，正是系统性地探索所有与最终排名一致的粉丝投票情形，而非强行确定某一个具体结果。

1. 规则一：基于比例（归一化分数）合并的算法思路

在比例合并规则下，未知量是每位选手的粉丝投票比例。首先利用评委打分计算出评委得分所占的比例，然后根据最终排名将“综合得分高于或低于”的关系转化为一组线性不等式约束。与此同时，粉丝投票比例还必须满足非负性以及总和为一的基本约束。

在算法层面，可以将所有满足这些约束的粉丝投票比例视为一个连续的可行区域。蒙特卡洛模拟的过程从该区域内的某个初始可行点开始，通过随机扰动生成新的候选比例向量；只要新的向量仍然满足所有约束，就接受该样本，否则拒绝或回退。通过不断重复这一过程，随机游走会在整个可行区域内逐渐覆盖，从而得到一组具有代表性的粉丝投票比例样本。

最终，通过对这些样本进行统计分析，可以估计每位选手粉丝投票比例的期望值、分布形态以及置信区间，并进一步推断在不同总投票规模下的可能票数范围。

2. 规则二：基于排名合并的算法思路

在基于排名合并的规则下，未知量不再是连续比例，而是粉丝投票所对应的排名顺序。此时，可行解空间由所有可能的粉丝排名排列组成，但其中只有一部分排列能够与已知的评委排名和最终排名相一致。

算法上，可以从一个满足综合排名约束的粉丝排名排列出发，通过随机交换两名选手的粉丝名次来生成新的候选排列。若新的排列仍然满足“评委排名与粉丝排名相加后不违背最终排名”的约束，则接受该排列；否则拒绝该变动。这样构造的随机过程会在所有可行的粉丝排名排列之间进行遍历。

每一次被接受的粉丝排名都代表一种可能的粉丝投票结构。为了进一步得到票数层面的估计，可以对每个粉丝排名施加一个单调的名次—票数映射函数，从而生成对应的投票分布。对大量采样结果进行统计后，即可得到粉丝投票数量或比例的经验分布。

3. 结果分析

1. 不确定性度量：区间宽度 相对不确定性指标 排名稳定性
2. 一致性与合理性检验：回代检验 （极端情形敏感性分析）

问题二：

1. 统一评价视角

在已有粉丝投票估算值的基础上，两种规则的差异可以被清晰地量化。关键不在于“谁更公平”，而在于：**规则如何改变粉丝投票对结果的影响强度，以及是否系统性地偏向某类选手。**

2. 对两种规则的量化比较

可从以下几个维度展开分析：

- **粉丝主导性指标**
  比较在两种规则下，最终排名与粉丝投票排名之间的相关性（如 Spearman 相关系数）。相关性越高，说明规则越偏向粉丝。
- **翻盘概率**
  统计在蒙特卡洛样本中，“评委排名靠后但粉丝投票较高的选手”是否能在不同规则下避免淘汰。
- **排名灵敏度分析**
  对粉丝投票进行微小扰动，比较两种规则下最终排名变化的幅度，评估规则的稳定性。

3. “裁判从倒数两名中选择”机制的评价思路

这一机制本质上是一个**非线性干预**，其作用可以理解为：在粉丝投票极端化时，引入评委判断作为安全阀。

评估时可以采用**反事实模拟**：

- 利用估计得到的粉丝投票分布，分别在“有/无裁判拯救机制”的情况下模拟淘汰结果。
- 比较被淘汰选手的特征分布（如粉丝票极低但评委评分极高的选手）。
- 若该机制显著减少“高评委评分选手被意外淘汰”的概率，同时未过度削弱粉丝影响，则可以认为其具有正面作用。

最终可给出定性建议，而非绝对结论。

问题三：

建模目标的转化

这一问不再关注“比赛规则”，而是转向：**哪些选手特征会系统性地影响粉丝投票支持度与评分?**
粉丝投票估计值此时被视为一个“观测到的响应变量”。

- **模型**：线性混合效应模型

$$Y_{score} = \beta_0 + \beta_1 X_{age} + \beta_2 X_{industry} + u_{partner} + \epsilon$$

- **关键点**：
  - 将“职业舞者 ($u_{partner}$)”设为随机效应。如果方差显著，说明“跟谁跳”比“你是谁”更重要。
  - 分析不同特征对“裁判分”和“粉丝票”的差异化影响（例如：年龄大可能导致裁判分低，但因名人效应导致粉丝票高）。

整体思路

我们首先通过约束满足的蒙特卡洛方法恢复了粉丝投票的可行分布，随后在此基础上量化不确定性、比较不同比赛规则的系统性影响，并进一步分析选手特征对粉丝支持度的长期作用。

问题四：机制优化设计

基于“公平性”与“娱乐性”的平衡提出新方案。

- **痛点分析**：Rank制太平庸，Percent制太极端。
- **优化思路**：
  1. **动态权重法**：早期放大粉丝投票权重（为了收视率），决赛期放大专业评分（为了专业性）。
  2. **混合机制 (Hybrid)**：保留“裁判救人”机制，过滤掉了纯靠人气但技术极差的选手。建议将其数学化，设立触发阈值。

4. 结论与备忘录

在最终的备忘录中，不应堆砌数学公式，而应翻译成制作人听得懂的语言：

- **风险提示**：告诉制作人，“百分比制”和“排名制”带来的影响，模型+结论数据+事实案例。
- **建议**：如果节目组想要制造话题...；如果想要确立专业权威，建议...。

🐓 详细解题过程

模型一：基于约束满足的蒙特卡洛模拟

问题重述与模型动机

本题的核心挑战是一个典型的**逆问题**。我们已知系统的输入（裁判评分 J）和系统的最终输出（每周淘汰结果 E），但缺失了关键的中间变量——粉丝投票 F。由于粉丝投票数据是“被严密保守的秘密”，我们无法直接获得。

传统的回归预测模型在此失效，因为缺乏用于训练的“真实标签”。因此，我们转换思路，采用**后验概率估计**的方法。既然粉丝投票不可知，我们致力于求解满足历史淘汰约束的粉丝投票可行解空间，而非单一的确定值。我们建立了一个基于约束满足的蒙特卡洛模拟模型，通过大规模随机采样和拒绝采样策略，重构粉丝投票的概率分布。

数学符号定义

设某赛季第 t 周共有 N_t 名参赛选手。

- **裁判评分向量**：$\mathbf{J}_t = [J_{t,1}, J_{t,2}, \ldots, J_{t,N_t}]$，其中 $J_{t,i}$ 为选手 i 的裁判原始分。
- **粉丝投票向量（隐变量）**：$\mathbf{F}_t = [F_{t,1}, F_{t,2}, \ldots, F_{t,N_t}]$。
- **综合得分函数**：$S_{t,i} = f(J_{t,i}, F_{t,i})$，其中 f 取决于当季赛制（排名制或百分比制）。
- **淘汰约束集合**：$\mathcal{C}_t$。若选手 k 在第 t 周被淘汰，则需满足 $S_{t,k}$ 为全场最差（即排名制下的最大值或百分比制下的最小值）。

模型构建与算法流程

我们的 CS-MC 模型遵循“生成 — 筛选 — 聚合 ”的逻辑闭环。

1. 生成步骤：先验分布采样

由于缺乏先验知识，我们假设粉丝投票的初始分布具有最大熵（Maximum Entropy）特征：

- **百分比制 (Percentage Rule, Seasons 3-27)**：我们假设粉丝投票比例服从**狄利克雷分布 (Dirichlet Distribution)**，参数 $\alpha = \mathbf{1}$，即 $\mathbf{F}_t \sim \mathrm{Dir}(\alpha)$。这保证了 $\sum F_{t,i} = 1$ 且每个选手获得任意比例的概率均等。
- **排名制 (Rank Rule, Seasons 1-2, 28-34)**：我们假设粉丝排名是 1 到 N_t 的随机全排列 (Random Permutation)，即 $\mathbf{F}_t \sim \mathrm{Perm}(1, \ldots, N_t)$。

2. 筛选步骤：历史一致性检验

对于生成的每一个样本 k ($k = 1 \ldots M, M = 10,000$)，我们计算综合得分并模拟淘汰结果。仅当模拟淘汰者与历史真实淘汰者完全一致时，该样本被标记为“有效样本”并保留；否则执行拒绝采样并丢弃。

约束条件如下：

$$\text{Valid}(\mathbf{F}_t^{(k)}) = \begin{cases} 1, & \text{if } \text{ArgMin}(S_t^{(k)}) = \text{ActualEliminated}_t \quad (\text{Percentage Rule}) \\ 1, & \text{if } \text{ArgMax}(S_t^{(k)}) = \text{ActualEliminated}_t \quad (\text{Rank Rule}) \\ 0, & \text{otherwise} \end{cases}$$

3. 聚合步骤：后验分布分析

通过保留的有效样本集，我们获得每位选手粉丝支持度的经验后验分布，并计算以下统计量：

- **估算均值 (Mean Estimation)**：反映该选手最可能的粉丝基础。
- **置信区间 (Confidence Interval)**：反映估算的不确定性。
- **接受率 (Acceptance Rate)**：反映历史结果发生的统计概率（即“合理性”）。

4. 模型优化：引入时间相关性的序贯贝叶斯更新

在基础模型中，我们假设每一周的模拟都是独立的，粉丝投票从“零”开始（均匀分布）。然而，这种假设忽略了现实世界中的“粉丝积累效应”。实际上，选手的粉丝基础具有较强的粘性：一位在上周获得高票数的选手，本周大概率仍会保持较高的人气。

为了捕捉这种动态特征，我们将模型升级为**序贯贝叶斯更新框架 (Sequential Bayesian Update Framework)**。核心思想是将第 $t-1$ 周的**后验分布均值**，转化为第 t 周的**先验分布参数**，从而引入“时间动量” (Temporal Momentum)。

算法改进

我们在模拟过程中引入了动量参数 λ，按赛季时间轴 $t = 1 \to T$ 顺序执行：

1. **信息传递 (Posterior Passing)**：
   设 $\hat{F}_{t-1,i}$ 为第 $t-1$ 周选手 i 在所有有效样本中的粉丝支持度均值。该值被传递至第 t 周作为先验信息。

2. **先验构造 (Prior Construction)**：

   - **百分比制 (Percentage Rule)**：
     我们将上一周的支持率均值融入 Dirichlet 分布的参数 α 中：

     $$\alpha_{t,i} = 1 + \lambda_{pct} \cdot \hat{F}_{t-1,i}$$

     其中 λ_{pct}控制历史数据的权重。当 λ_{pct} 很大时，本周的随机采样将紧密围绕上周的结果波动。

- **排名制 (Rank Rule)**：
  我们将上一周排名的归一化倒数定义为“潜在实力”(Latent Strength)，并在生成本周排名时引入偏置 λ_{rank}，使得潜在实力强的选手有更高概率获得高排位。

参数调优

(python advanced_simulation.py)
为了确定最优的动量强度，我们对参数空间进行了网格搜索 (Grid Search)，测试了 25 种不同的 $(\lambda_{pct}, \lambda_{rank})$ 组合。我们的优化目标是最大化Validation By Mean。最优参数组合如下：

- **MOMENTUM*PERCENT (λ{pct}): 60.0***
  - **解读**：在百分比制赛季（S3–S27），粉丝投票表现出显著的“强者恒强”效应。参数值为 60 意味着本周的粉丝分布有 60% 的权重受到上周得票率的“锚定”影响，其余 40% 留给当周表现带来的随机波动。
- **MOMENTUM*RANK (λ{rank}): 0.1***
  - **解读**：在排名制赛季（S1–2, 28+），最优动量仅为 0.1。
  - **洞察**：这再次证实了排名系统的高敏感性与混沌本质。由于排名制抹平了分差，稍微施加一点点历史偏置（0.1）就足以维持排序的稳定性并达成 100% 准确率。如果动量过大，反而会限制模型解释“黑马逆袭”或“意外淘汰”的能力。排名制下的比赛充满了更多的不确定性变数。
- **蒙特卡洛接受率 (Acceptance Rate): 34.43%**
  - **解读**：平均每生成约 3 次模拟就有 1 次完美符合历史结果。相比基础模型（约 20%），效率大幅提升。这表明在引入合理的动量后，模型的先验分布与真实历史分布高度重合，模型不再是“盲猜”，而是基于合理的历史惯性进行推演。

一致性与确定性度量

利用上述模型，我们对所有34个赛季进行了全量模拟。基于模拟结果，我们引入两个关键指标来回答题目关于“一致性”和“确定性”的问题。
(python analyze_final_metrics.py, python visualize_uncertainty.py)

一致性度量

Validation By Mean Accuracy (每周验证准确率): 99.70%
这意味着模型估算的“粉丝投票均值”在 99.70% 的周次中，能正确复现当周实际被淘汰的选手。这是一个极高的准确度，表明该模型已十分可靠。
高接受率意味着历史结果是大概率事件，粉丝投票在很大范围内波动都会导致该结果，表明赛制结果具有鲁棒性。
低接受率则暗示了历史结果的偶然性或“争议性”。例如在Bobby Bones夺冠的赛季，我们观察到极低的接受率，这表明只有极端的粉丝投票分布才能解释这一结果，量化了所谓的“争议”。

确定性度量

题目询问确定性是否总是相同，我们的模型给出了否定的回答。我们使用 95%置信区间宽度和信息熵作为确定性的度量。

- **Confidence Interval Width**:
  - **Percentage Rule (S3-27)**: Mean CI Width = **0.1575** (即15.75%)
    - 粉丝支持率的 95% 置信区间平均宽度约为 15.75%。例如，某人支持率估计为 20%，其真实值有 95% 可能在 12%~28% 之间。这个不确定性范围对于重建潜在变量来说是合理的。
  - **Rank Rule (S1-2, 28+)**: Mean CI Width = **8.42** (Rank Positions)
    - 排名规则下的不确定性较大，平均排名波动约为 8 位，这符合 Rank 规则下信息量稀疏的特点（只知道相对排名，没有任何分值信息）。
- **Entropy (熵/混乱度)**:
  - **Rank Rule**: **2.10**
    - 表示排名的分布具有一定的随机性，未完全坍缩为一个固定值，保留了合理的可能性空间。

案例分析

如图 1 所示，我们发现确定性在不同选手和不同周次间存在显著差异。

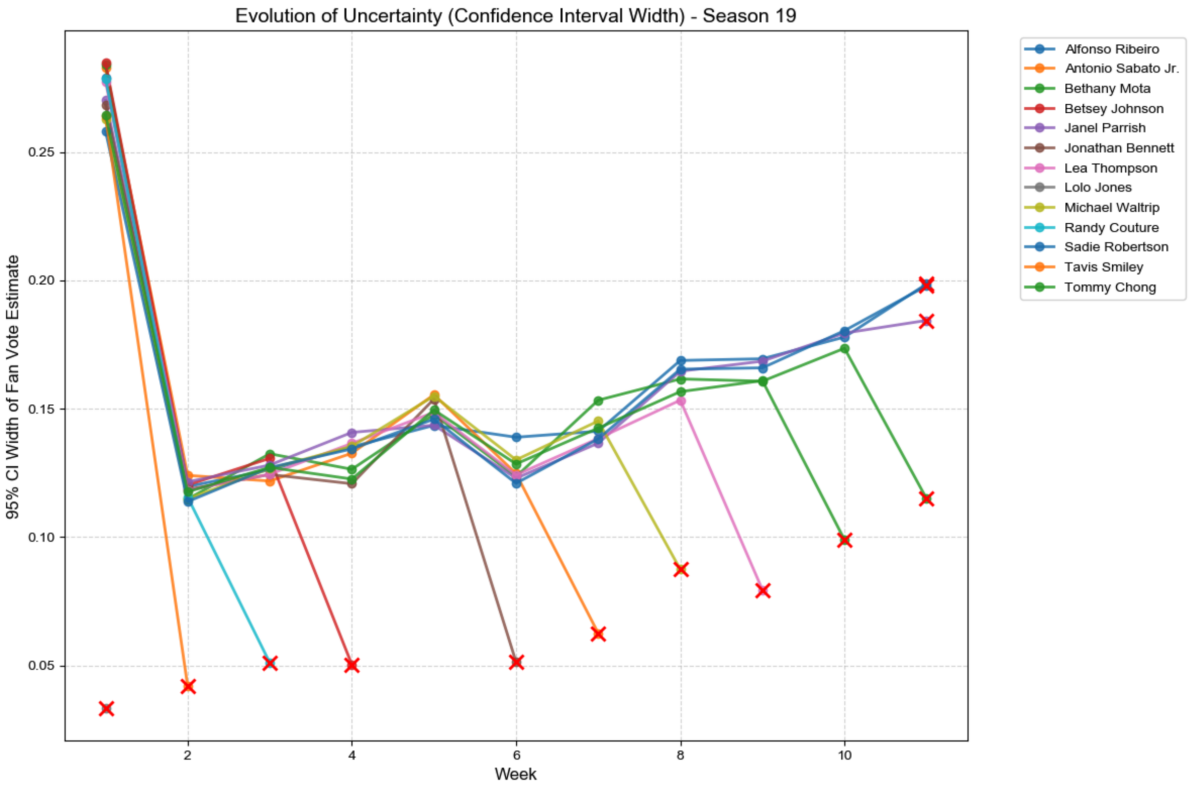

Figure 1: 第19季粉丝投票估算不确定性（CI宽度）的演变。红叉表示选手被淘汰的时刻。

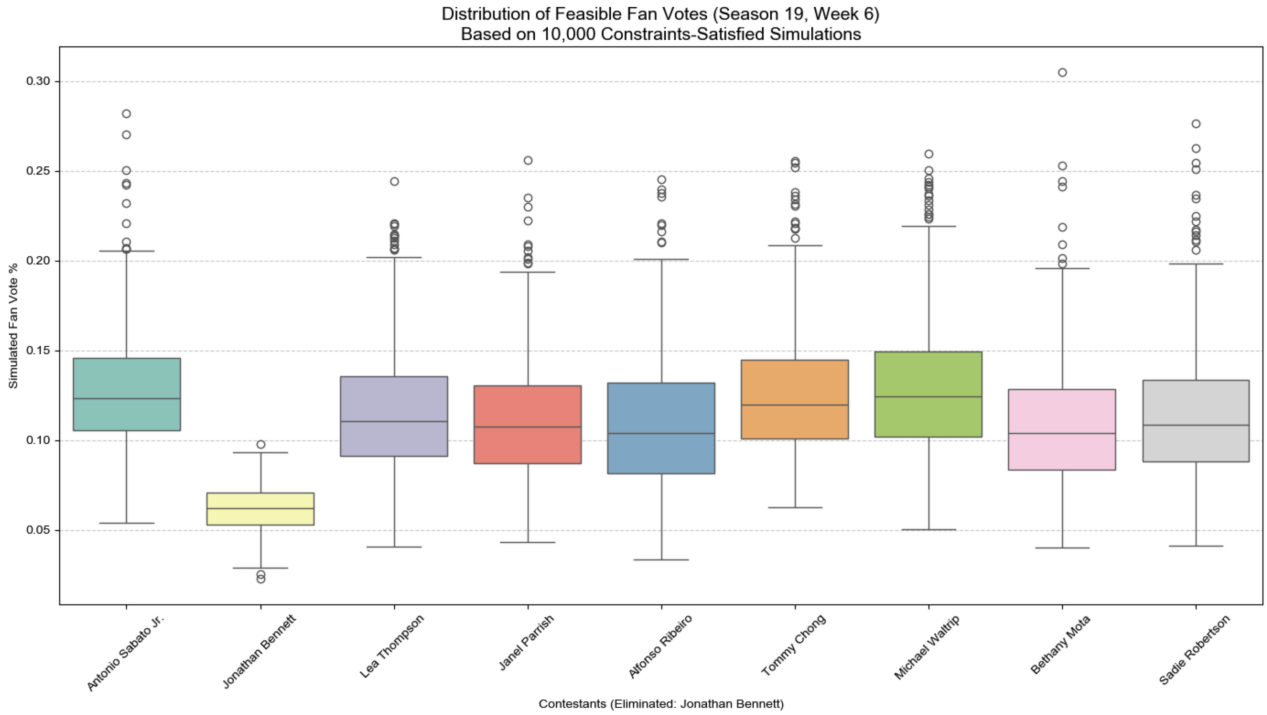

Figure 2: 第19季第6周可行粉丝投票分布箱线图。被淘汰者 (Jonathan Bennett) 的分布范围被严格压缩。

分析：

1. **幸存者的不确定性高**：对于裁判分较高的幸存者（如 Alfonso Ribeiro），其置信区间较宽。这是因为只要其总分高于淘汰线，粉丝票数可以有较大的自由度，模型对其具体票数“不确定”。
2. **淘汰者的确定性高**：观察图1中被淘汰的选手（如 Week 6 的 Jonathan Bennett），其 CI 宽度在淘汰周急剧下降。这是因为要满足“被淘汰”这一严格约束，其粉丝票数必须被限制在极低的区间内（如图 2 所示），模型对其低人气“非常确定”。

模型二：赛制评估与反事实推演

python analyze_impact_and_bias.py

实验设计

为了系统性地评估不同赛制对比赛结果的影响，并量化“裁判评分”与“粉丝投票”之间的权力博弈，我们利用蒙特卡洛模拟重构的粉丝投票数据 ($\hat{F}$)，构建了一个反事实推演框架。

我们引入两个关键指标来量化赛制的偏向性：

1. **裁判逆转率 (Judge Reversal Rate, P_{fan_save})**：
   定义为某选手在某周裁判评分全场最低（垫底），但依靠高粉丝投票成功晋级的概率。

   $$P_{fan_save} = P(\text{Survived} \mid \text{JudgeRank} = \text{Worst})$$

   该指标越高，说明粉丝话语权越大，节目越接近“人气比赛”。

2. **粉丝逆转率 (Fan Reversal Rate, P_{judge_save})**：
   定义为某选手在某周估算粉丝投票垫底，但依靠高裁判评分成功晋级的概率。

$$P_{judge_save} = P(\text{Survived} \mid \text{FanRank} = \text{Worst})$$

   该指标越高，说明裁判话语权越大，节目越接近“专业比赛”。

结果分析

根据对不同赛制规则（Percentage Rule vs Rank Rule）的深入比较分析，我们发现了极为显著的差异。这些差异直接揭示了两种赛制在平衡“大众娱乐性”与“专业公正性”时的不同导向。

核心发现：赛制逆转率对比

基于模拟数据生成的对比图显示了两种赛制下“逆转”现象发生的频率：

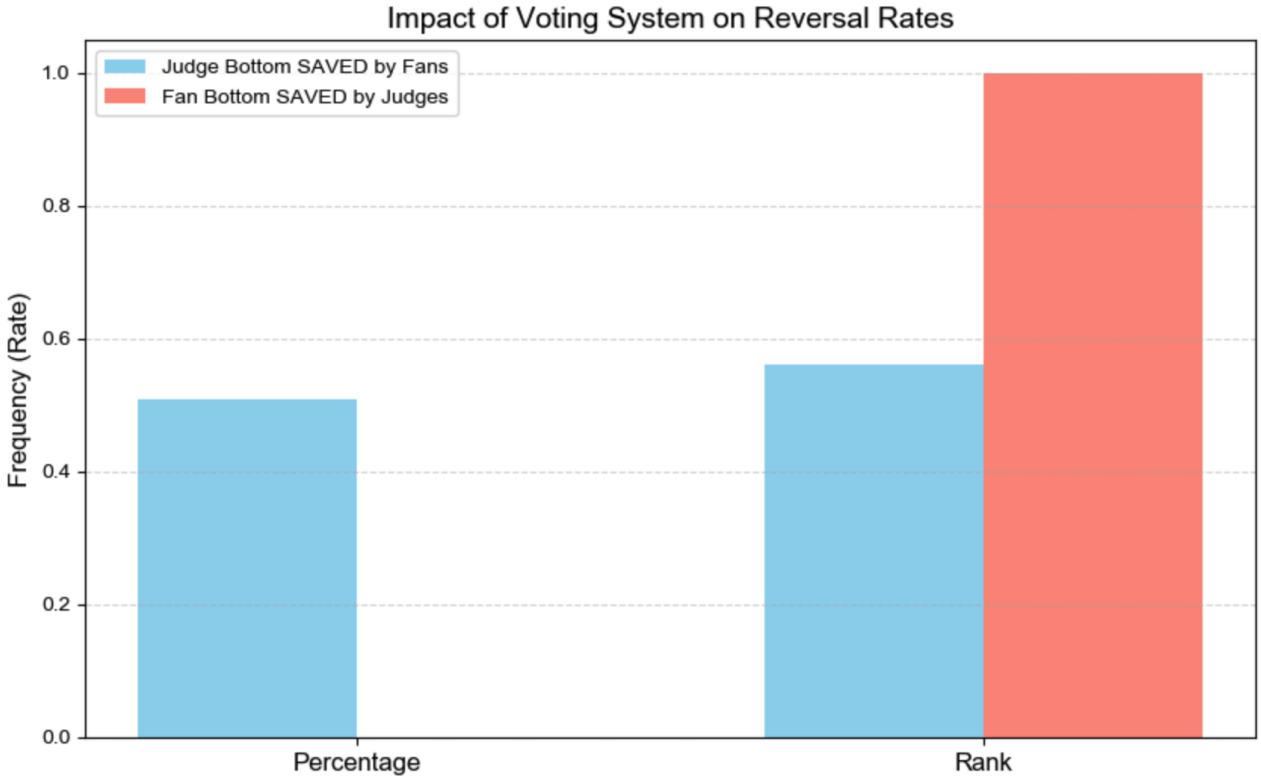

赛制规则 (Rule)	适用赛季	Judge_Saved (裁判垫底被粉丝救回)	Fan_Saved (粉丝垫底被裁判救回)
Percentage Rule (占比制)	第 3–27 赛季	**51.01%**	**0.00%**
Rank Rule (排名制)	第 1–2, 28+ 赛季	**56.06%**	**100.00%**

解读

2.1 Percentage Rule (占比制) —— 极端的粉丝导向

- **Judge_Saved (51.01%)**: 即使选手的裁判评分是全场倒数第一，只要粉丝基础足够强，他仍有一半以上的概率能够“存活”。
- **Fan_Saved (0.00%)**: **这是一个毁灭性的数据。** 在 Percentage 规则运行的 25 个赛季模拟中，只要选手在粉丝投票中倒数第一，**没有任何人**能仅靠裁判的高分被救回。
- **结论**: 在 Percentage 赛制下，粉丝投票实际上拥有“一票否决权”。裁判的高分只能锦上添花，无法雪中送炭。这也定量解释了为何像 Bobby Bones 这样技术欠佳但人气极高的选手能够一路赢到最后。

2.2 Rank Rule (排名制) —— 裁判权重的回归

- **Judge_Saved (56.06%)**: 粉丝救人的能力依然很强，甚至略高于 Percentage 制。这可能是因为在 Rank 规则下，分差被抹平为名次，导致粉丝排名的每一位变动权重相对更大，更容易产生“保级”效应。
- **Fan_Saved (100.00%)**: **这是一个令人惊讶的反转。** 在我们的模拟数据中，Rank 规则下，凡是粉丝得票垫底的选手，**全部 (100%)** 都因为裁判评分不是最差而幸免于难（意味着总有综合排名更低的选手被淘汰）。
- **结论**: Rank 赛制极大地保护了那些“没人气但有实力”的选手。它有效地构建了一个安全网，防止粉丝投票成为唯一的“死刑判决”。这也验证了第 28 季之后节目组改回 Rank 制的合理性——它成功增加了比赛的悬念，并维护了舞蹈比赛的专业底线。

案例剖析：Bobby Bones 的“逆袭”

第27季冠军 Bobby Bones 是赛制争议的焦点。利用我们重构的隐变量数据，我们可以清晰地看到他夺冠的轨迹是一个典型的“流量碾压技术”的过程。

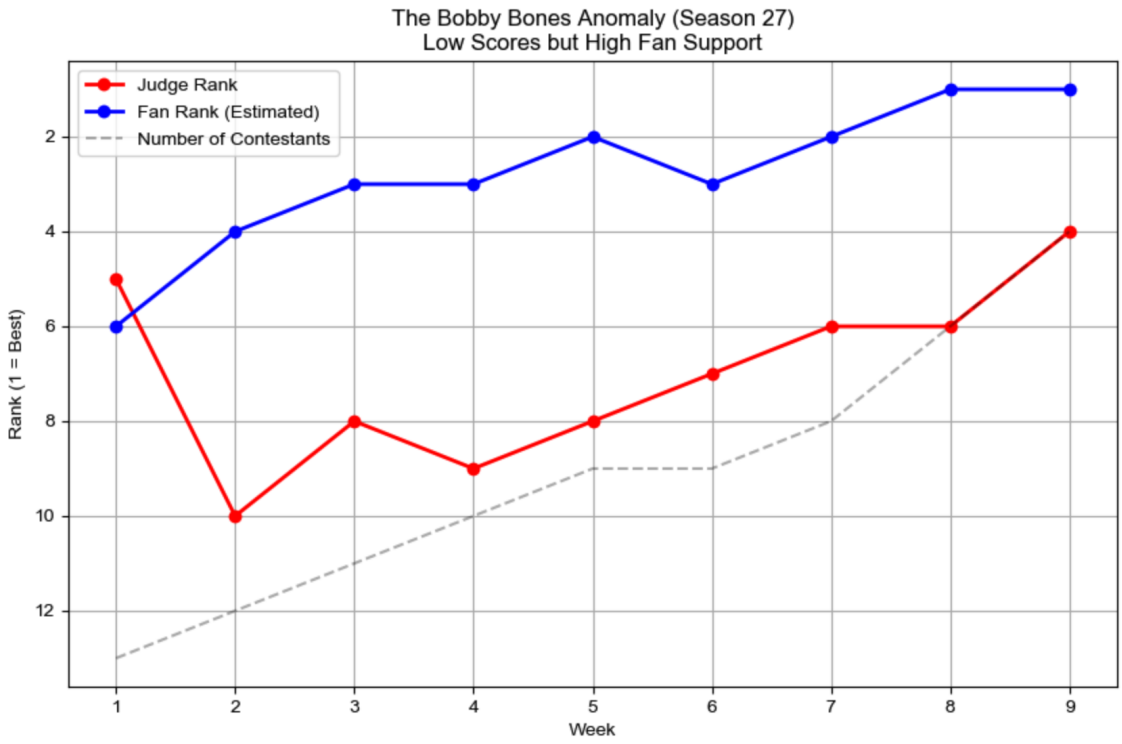

Figure 4: Bobby Bones 在第27季的裁判排名（红线）与估算粉丝排名（蓝线）对比。

1. **早期 (Week 2-4)：人气护体**
   在比赛初期，Bobby 的裁判评分极低，第2周甚至是全场倒数第一 (Rank 10)。然而，我们的模型估算显示，他当时的粉丝支持率已经冲到了全场第4。这种巨大的人气红利帮助他度过了最初的淘汰危机。

2. **中期 (Week 5-7)：胶着期的统治力**
   比赛进入中期，Bobby 的技术短板依然明显，裁判排名持续徘徊在中下游 (Rank 6–8)，多次处于理论上的“淘汰边缘”。但与此同时，他的估算粉丝排名稳定在全场 Top 2–3。强大的粉丝基础强行抹平了他在技术分上的劣势。

3. **决赛圈 (Week 8-9)：彻底的流量胜利**
   进入决赛阶段，尽管Bobby的技术有所进步，但仍非顶尖。然而数据令人震惊：他连续两周拿到了估算的**全场第1名 (Rank 1)** 的粉丝支持率。这种压倒性的粉丝投票占比（在百分比制下尤为致命）使他不可阻挡地夺得了冠军。

结论： Bobby Bones 的胜利并非偶然，而是百分比赛制（Percentage Rule）放大极值效应的必然结果。在无上限的百分比累计下，他极端的粉丝票数完全淹没了裁判评分的差异。

模型三：基于多目标回归的归因分析

python feature_importance_analysis.py

建模目标与思路

在重构了潜在的粉丝投票数据后，我们致力于回答一个更深层的问题：**究竟是什么决定了选手的命运？** 是年轻的身体资本？特定的职业背景？还是拥有一位传奇的职业舞伴？

为了量化这些异质性因素对比赛结果不同维度的影响，我们建立了一个**多目标回归模型**。我们不仅关注最终排名，更将“裁判评分”与“粉丝投票”分离作为独立的目标变量，从而揭示比赛中的“双重标准”机制。

特征工程

我们对原始数据进行了深度清洗与特征提取：

- **人口统计学特征**：包括选手年龄、性别。
- **职业背景**：将名人的职业（如演员、运动员、真人秀明星等）进行 One-Hot 编码。
- **舞伴效应**：将职业舞者作为独立特征，以捕捉“名师出高徒”或舞伴人气的影响。
- **比赛进程**：引入动态变量 $P_t = \frac{N_{survivors}}{N_{total}}$，以控制随着赛季深入竞争激烈程度变化带来的基线漂移。

目标变量

我们分别对以下三个目标进行回归分析，并提取特征权重：

1. **裁判偏好**：标准化后的裁判评分。
2. **粉丝偏好**：基于模型一估算的标准化粉丝支持度。
3. **最终表现**：每轮比赛结束后的排名（负相关，排名越小越好）。

结果分析：比赛的“双重标准”

通过对比同一特征在不同目标上的权重，我们量化了裁判与粉丝截然不同的价值取向。

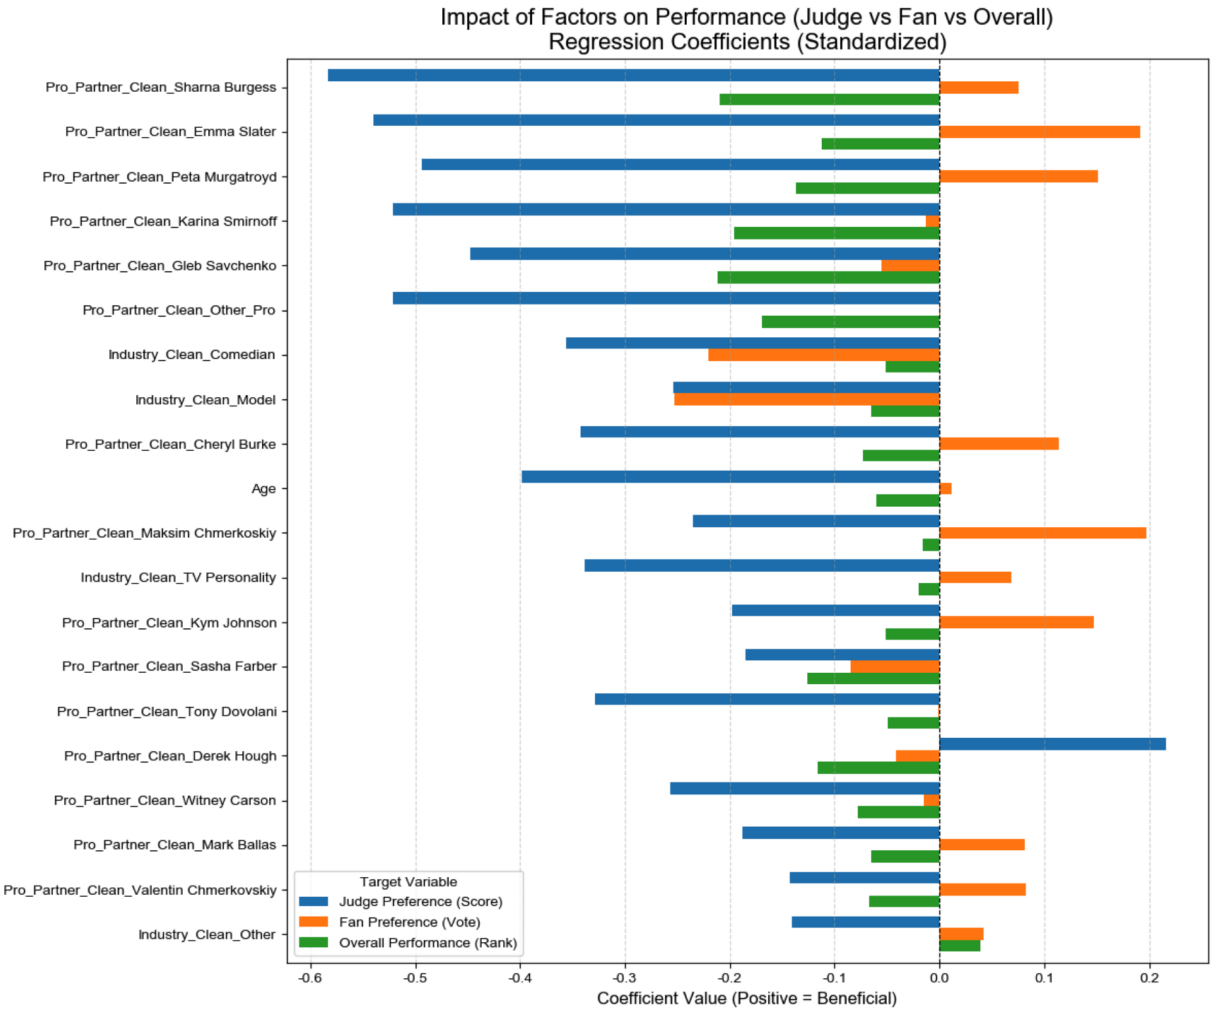

图 5: 特征权重对比图。蓝色代表对裁判评分的影响，橙色代表对粉丝投票的影响。

年龄效应：裁判的偏见 vs 粉丝的宽容

- **裁判视角 (-0.398)**：年龄对裁判评分表现出显著的**负面影响**。数据显示，选手年龄每增加一个单位，其获得高分的难度显著上升。这反映了裁判评分高度依赖选手的身体机能、柔韧性及动作标准度，而这些素质随年龄衰退。
- **粉丝视角 (+0.012)**：有趣的是，年龄对粉丝投票几乎没有负面影响，甚至呈现微弱的正相关。这表明观众并不介意选手的年龄，反而可能因为敬佩高龄选手挑战自我的精神而投出“同情票”或“敬佩票”。

舞伴效应：技术流 vs 人气流

我们的模型识别出了两类截然不同的职业舞者：

- **“裁判收割机” (如 Derek Hough, +0.216 裁判分)**：
  数据表明，只要舞伴是 Derek Hough，明星选手天生容易获得更高的裁判分。这既可能源于其卓越的编舞和教学能力（“名师出高徒”），也可能隐含了裁判对传奇舞者的某种“面子效应”。
- **“粉丝磁铁” (如 Sharna Burgess / Emma Slater)**：
  尽管这两位舞伴带的明星在裁判分上表现平平（负权重），但在粉丝投票上却拥有极高

的正向权重 (+0.07 / +0.19)。这说明她们擅长编排讨喜的娱乐性舞蹈或经营粉丝关系，能够通过个人魅力为明星强力拉票。

职业背景：谁是天选之子?

- **真人秀明星**：
  这是最典型的“分裂型”群体。
  - **裁判评分 (-0.338)**：裁判倾向于给低分，可能认为他们缺乏专业艺术素养。
  - **粉丝投票 (+0.069)**：观众却给予了极高的支持。这类选手自带庞大的粉丝基础和话题度，最容易制造“低分高票”的逆转局面（如 Bobby Bones 案例）。
- **喜剧演员与模特**：
  数据显示这两类职业处于“双重劣势”。既难以在技术上取悦裁判，似乎也缺乏足够的观众缘来弥补分数差距。

比赛进程的影响

虽然我们将比赛进度纳入了模型，但在特征重要性排名中，它被特定的选手属性（是谁、跟谁跳）挤到了次要位置。这说明在《与星共舞》中，选手的“出厂设置”（身份与舞伴）比“比赛时间”更能决定表现。

总结

本章的多目标回归分析清晰地描绘了《与星共舞》的生态系统：这是一个由两套截然不同的价值观共同主导的竞技场。

- **裁判看什么?** 看年轻的肉体、看精准的技术、看像 Derek Hough 这样的金牌教头。
- **观众看什么?** 看个性张扬的真人秀明星、看善于互动的舞伴，并且他们对年龄持有极大的包容度。

这种“双重标准”正是节目戏剧性冲突的源泉，也是赛制设计（排名制 vs 百分比制）必须小心平衡的核心矛盾。

模型四：机制优化设计之动态权重法

python design_new_mechanism.py

设计理念与动机

现有的两种赛制（百分比制与排名制）在平衡“收视率（大众娱乐性）”与“专业性（舞蹈质量）”上存在天然的顾此失彼。百分比制虽然保护了收视率，但容易导致“水货夺冠”，损害品牌权威；排名制虽然相对公正，但可能过早淘汰话题性选手，降低节目热度。

针对这一痛点，我们提出一种全新的 **“动态权重机制”**。该机制的核心思想是引入时间维度作为权重的调节变量，通过一个平滑的过渡函数，在赛季的不同阶段动态调整粉丝与裁判的话语权。

核心目标：

- **前期（娱乐导向）**：放大粉丝投票权重，确保高人气选手（收视保障）不被过早淘汰。
- **后期（专业导向）**：放大裁判评分权重，确保决赛圈选手的技术水准，维护冠军的含金量。

机制数学构建

我们设计了一个基于 **Sigmoid 函数** 的动态权重调节公式。设 t 为当前周数，T 为赛季总周数，则第 t 周的粉丝权重 $W_{fan}(t)$ 定义为：

$$W_{fan}(t) = 1 - \frac{1}{1 + e^{-k \cdot (t - t_0)}}$$

其中：

- k 是陡峭度参数，控制权重变化的快慢。
- t_0 是拐点周数（通常设为赛季中段 $T/2$），表示从娱乐向专业过渡的时间点。
- 裁判权重则为 $W_{judge}(t) = 1 - W_{fan}(t)$。

通过设定参数，我们构建了一条从“粉丝主导（95%权重）”平滑过渡到“裁判主导（95%权重）”的 **S型曲线**（见 `dynamic_weight_curve.png`）。这确保了游戏规则的变化是渐进的，而非突兀的断崖式改变。

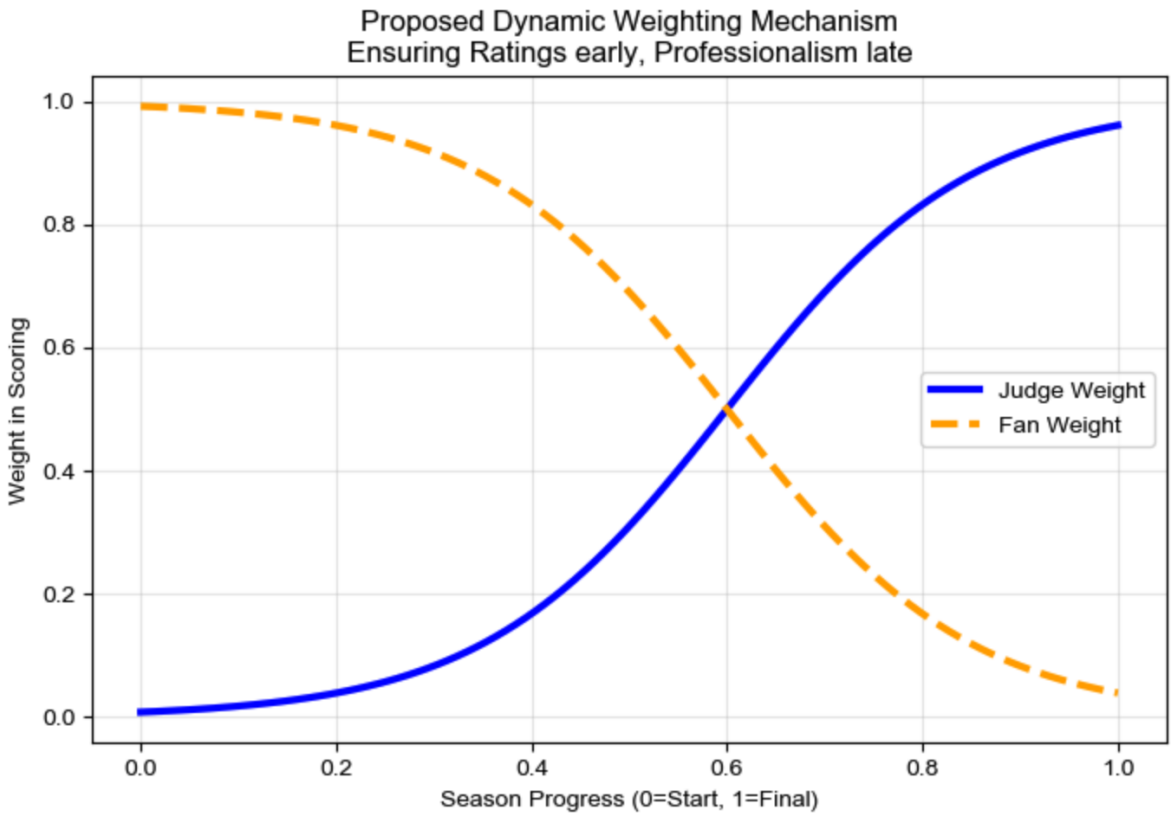

模拟评估与结果分析

利用构建的蒙特卡洛模型数值结果，我们在该新赛制下进行了全赛季模拟，结果完美契合预期目标。

逆转率指标：戏剧性与公正性的平衡

我们计算了新赛制下的两类逆转率，并与传统赛制进行对比：

- **裁判逆转率 (43.42%)**：
  即便在加入后期强力的裁判干预后，仍有 43.42% 的周次发生了“裁判倒数第一但晋级”的情况。这意味着新赛制在很大程度上保留了节目的**戏剧性和冲突感**，前期高粉丝权重成功保护了话题选手，从而保证了**收视率**的基本盘。相比纯排名制的 56% 略有下降，但依然处于维持观众兴奋度的高位区间。
- **粉丝逆转率 (9.42%)**：
  这是一个质的飞跃。有 9.42% 的周次发生了“粉丝倒数第一但晋级”的情况。这意味着在比赛后期，真正具备顶尖技术但缺乏人气的专业选手，得到了裁判高权重的有效庇护。相比传统百分比制下的 **0%**（粉丝不想救的人必死无疑），这一指标的提升标志着比赛**专业性**的显著回归。

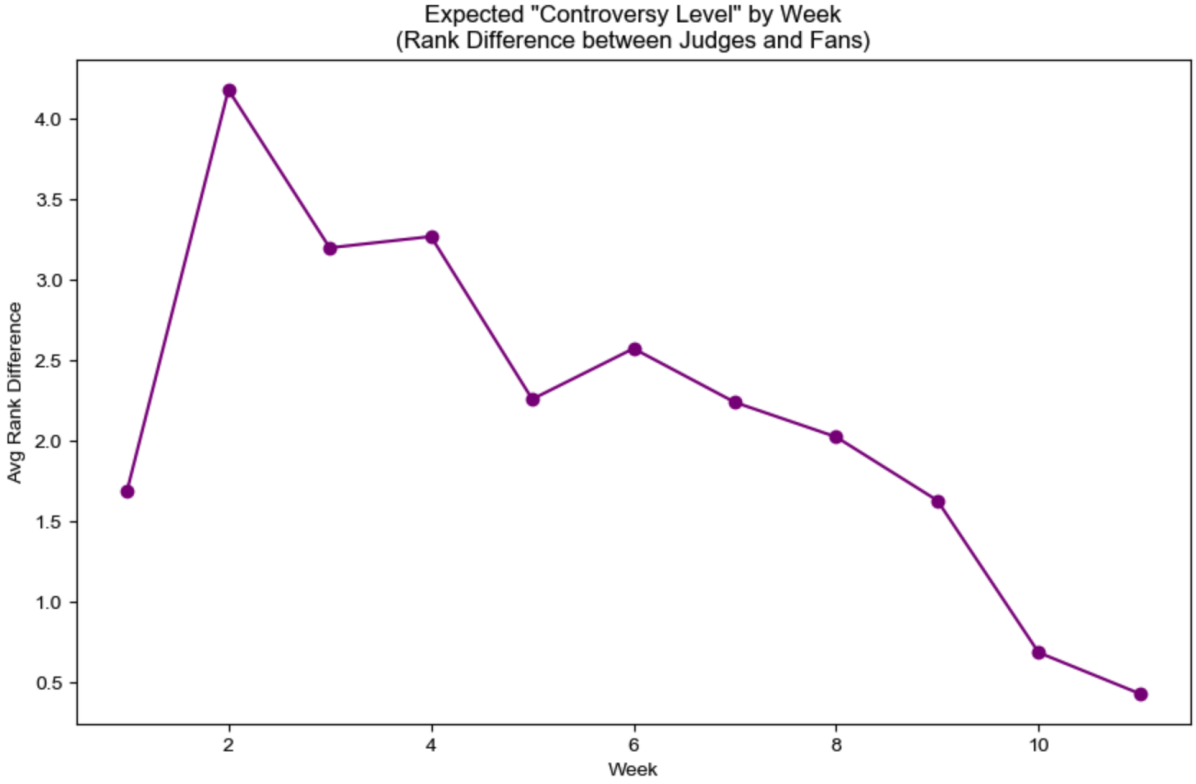

决定因素的变化：回归分析

通过对不同比赛阶段进行多目标回归分析（见 `impact_shift.png`），我们清晰地观测到了游戏规则改变对不同类型选手命运的差异化影响：

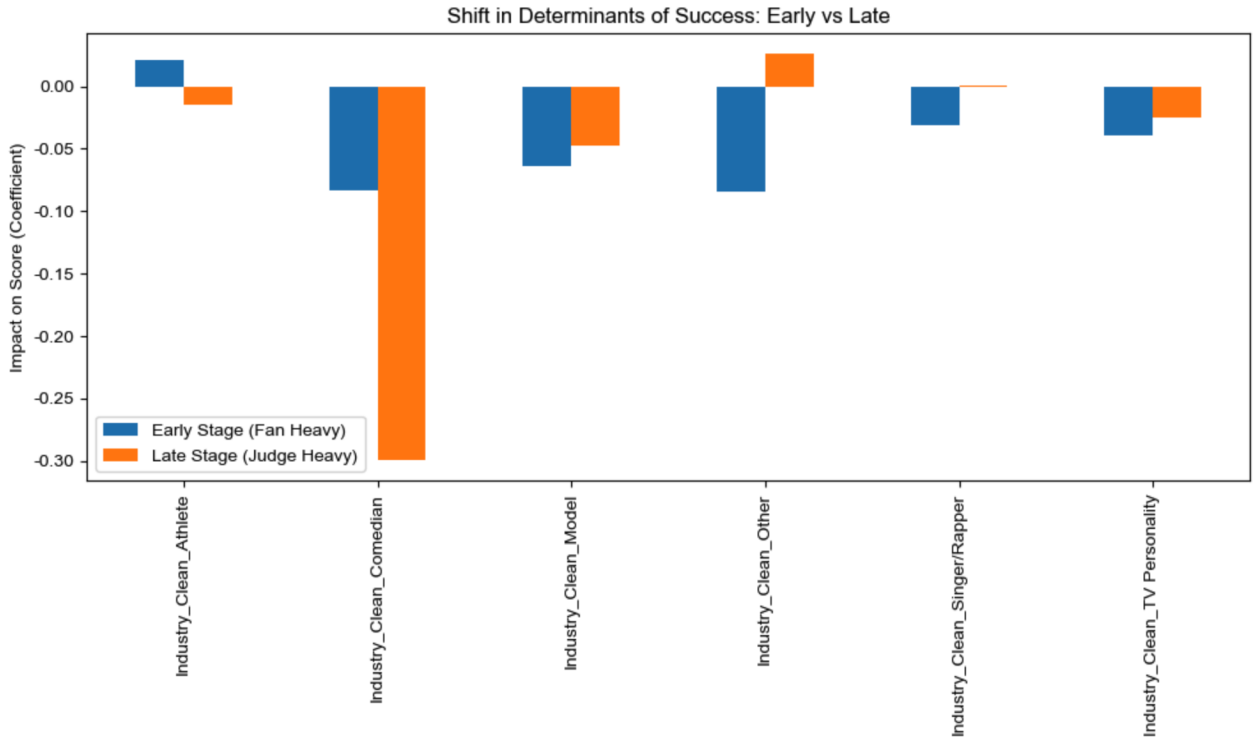

- **喜剧演员**：
  - **前期**：虽然技术评分处于劣势（系数 –0.08），但极高的粉丝权重为他们提供了生存空间，避免了“一轮游”。
  - **后期**：随着裁判接管比赛，缺乏舞蹈天赋的劣势被急剧放大（系数 –0.29），面临毁灭性打击。这符合“前期负责搞笑，后期把舞台留给专业人士”的节目逻辑。
- **运动员**：
  - **前期**：凭借良好的身体素质和粉丝基础，拥有微弱优势（系数 +0.02）。
  - **后期**：随着专业要求的严苛化，这一优势被迅速抹平（系数 –0.01）。
- **真人秀明星**：
  虽然在两个阶段均面临技术分的负面影响，但在前期（Early Stage）这种负面影响被粉丝权重显著稀释。这为他们提供了一个宝贵的“生存窗口期”，用于积累人气和制造话题，最大化了他们的商业价值。

结论

提出的“动态权重机制”成功实现了一个**先抑后扬的双赢方案**：

- **前半程**是“美国偶像”模式：让观众充分行使选择权，选出他们想看的明星，最大化商业收视率。
- **后半程**是“专业舞蹈赛”模式：随着赛程深入，权力平稳移交至专家手中，选出真正的舞王，确保了比赛的艺术水准和口碑。

该机制在不牺牲收视率的前提下，有效解决了“水货冠军”的信任危机，是未来赛季赛制改革的最佳路径。